

ANTALYA • LLM TABANLI UYGULAMA GELİŞTİRME

Gemma 4 (E4B) Fine-Tuning ile Metinden JSON'a

Dağınık belgeyi, şemaya uyan geçerli JSON'a çeviren bir model eğitiyoruz.

Unsloth • QLoRA (4-bit) — Kaggle / Colab ücretsiz T4 GPU

Dr. Murat Altun



Neden fine-tune? Prompt yetmiyor mu?

Küçük bir modele prompt ile JSON istediğinizde tipik üç sorun:

1

Gevezelik

"İşte JSON'unuz:" gibi giriş ekler; kod bloğu (```) sarar → json.loads() patlar.

2

Şemadan sapma

Alan adını değiştirir, tip tutmaz, olmayan alan uydurur.

3

Tutarsızlık

Aynı girdi, her çağrıda farklı biçim → otomasyona güvenilmez.

PROMPT-ONLY ÇIKTISI

Tabii! İşte istediğiniz JSON:

```
```json
{
 "ad": "Jane",
 "yas": "kırk",
 "tarih": 2023-03-08
}
```
```

✗ giriş cümlesi ✗ tip hatası ("kırk") ✗ tarih tırnaksız

Prompt mı, RAG mı, Fine-tune mı?

Doğru araç, çözdüğünüz probleme bağlı. Bizim sorunumuz: format disiplini.

Prompt Engineering

- + Hızlı, sıfır ek maliyet, anında dener.
- Davranışı KALICI değiştiremez; her istekte tekrar tarif.

RAG

- + Modele güncel / dış bilgi ekler.
- Çıktı FORMATINI ve tarzını öğretmez; sadece bağlam verir.

BİZİM SEÇİMİMİZ

Fine-tune

- + Format + davranışı ağırlıklara KALICI işler.
- Veri + kısa eğitim gerekir (ama QLoRA ile ucuz).

Format tutarlılığı = fine-tune probleminin ta kendisi.

İki temel kavram (30 saniyede)

1 · Base mı, Instruct mı?

Base (temel): ham cümle tamamlayıcı. "Başkent?" → cevap vermez, cümleyi sürdürür. Sıfırdan hizalama için.

Instruct (-it): komut anlar, cevap verir. BİZ BUNU seçiyoruz — sadece davranışı incelteceğiz.

2 · Quantization — niçin 4-bit?

Modeli belleğe sığdırmak için sayı hassasiyetini düşürürüz.

16-bit · ~10+ GB · T4'e sığmaz

4-bit · ~6 GB · sığar ✓

Doğrulukta ihmal edilebilir kayıp, bellekte ~2.5× küçülme. QLoRA'nın tabanı budur.

QLoRA: E4B'yi tek T4'te eğitmek

 Gemma 4 E4B — DONDURULMUŞ

4-bit nicelenmiş taban ağırlıklar
(eğitilmez, ~6 GB VRAM)



LoRA adaptörleri — EĞİTİLİR (küçük)

Ağırlıklar donuk; sadece küçük adaptör matrisleri öğrenir.

~6 GB

4-bit taban VRAM ayak izi

~0.5%

gerçekten eğitilen parametre oranı

$r = 8 \cdot \alpha = 8$

kompakt adaptör; küçük veri için ideal

Yığın ve Veri Seti

Teknoloji Yığını

1

Gemma 4 E4B

Google açık ağırlık (apache-2.0); Gemini değil

2

Unsloth

Transformers üzerine; 1.6× hız, %60 az VRAM

3

QLoRA (4-bit)

tam fine-tune yerine adaptör

4

Kaggle / Colab T4

ücretsiz GPU, üyelik gerekmez

VERİ SETİ

paraloq / json_data_extraction

484


örnek belge
(metin + şema → JSON)

8 alan tıp · e-ticaret · üretim · haber...

text-only (görsel yok → T4'e uygun)

apache-2.0 lisans — özgürce kullanılır

7 Adımda Uygulama Hattı



Adım 5 ↔ 7: aynı testte önce ve sonra — bilimsel karşılaştırma.

Ölçmeden "iyi oldu" demeyiz

Metrik = geçerli-JSON oranı (`json.loads()` başarısı) · ayrı test seti · data leakage yok

BASELINE

~60%

fine-tune ÖNCESİ
geçerli JSON



FINE-TUNED

~95%+

fine-tune SONRASI
geçerli JSON

Değerler temsilidir — gerçek oran eğitimde ölçülür. Önemli olan yöntem: baseline → eğit → aynı testte ölç.

Canlı Demo — Kaggle'da beş tık

1

Yeni Notebook

kaggle.com → Create → Notebook

2

Accelerator = GPU T4 x2

sağ panel → Session options

3

Internet = On

model + veri indirilecek

4

Run All

hücreler sırayla akar

5

10–15 dk bekle

eğitim + önce/sonra kıyas ekrana düşer

💡 **İPUCU**

Öğrenciye önce baseline hücrelerini gösterin
— model gevezelik / bozuk JSON üretir.

Sonra eğitim + sonrası hücresi ile aynı
örneğin tertemiz JSON'a döndüğünü canlı
gösterin.

Fark = ders.

Sıra Sizde — Geniřletme Ödevleri

1

Tam eğitim

max_steps yerine num_train_epochs=2; oranı yeniden ölçün.

2

Şema doğrulama

jsonschema.validate ile şemaya uygunluk + alan F1 ekleyin.

3

Hiperparametre

r ve α 'yı 8→16→32 tarayıp etkisini gözlemleyin.

4

Kendi veriniz

Türkçe fatura / dilekçe → JSON veri setiyle aynı hattı çalıştırın.

5

Yerel dağıtım

GGUF'a çevirip Ollama ile mini bir çıkarım API'sine bağlayın.

6

Karşılaştırma

Aynı görevi salt-prompt ile deneyip fine-tune ile kıyaslayın.

Küçük model, doğru veriyle büyük iş yapar.



- ✓ QLoRA ile Gemma 4 E4B'yi ücretsiz GPU'da fine-tune ettik
- ✓ gemma-4 şablonu + train_on_responses_only ile modeli geçerli JSON'a şartladık
- ✓ Baseline → SFT → ölçüm ile iyileşmeyi objektif kanıtladık