

Gemma 3 (4B) Fine-Tuning Notebook'u — Nasıl Çalıştırılır?

Antalya LLM Tabanlı Uygulama Geliştirme Eğitimi • Dr. Murat Altun

Bu rehber, [gemma3_json_finetune.ipynb](#) dosyasını **ücretsiz** bir GPU üzerinde uçtan uca çalıştırmayı adım adım anlatır. Kod bilmenize gerek yok — hücreleri sırayla çalıştırmanız yeterli.

Notebook ne yapıyor? Dağınık bir belgeyi (fatura, tıbbi kayıt, sipariş...) + bir JSON şemasını alıp, şemaya birebir uyan **geçerli JSON** üreten bir model eğitir. **Gemma 3 4B**'yi **QLoRA** ile tek ücretsiz T4 GPU'da fine-tune ederiz.

✅ **Kaggle T4'te gerçek sonuç:** Geçerli-JSON oranı fine-tune öncesi **%0** → sonrası **%95**. Yükleme 4.6 GB, eğitim peak VRAM 5.9 GB.

0. Önce kısa kavramlar (LoRA / QLoRA nedir?)

Kavram	Bir cümlede
Base vs Instruct (-it)	Base model ham cümle tamamlayıcıdır; Instruct (bizim kullandığımız -it) komut anlar, cevap verir.
Quantization (4-bit)	Modelin 16-bit hali ~8 GB; 4-bit 'e sıkıştırınca ~3 GB → ücretsiz GPU'ya sığar, doğrulukta ihmal edilebilir kayıp.
LoRA	Donuk modeli baştan yazmak yerine kenara küçük "not kağıtları" iliştiririz. Model aynı kalır, notlar görevi öğrenir.
QLoRA	LoRA + 4-bit taban. Sadece parametrenin ~%0.5'ini eğitiriz → ucuz, hızlı, ücretsiz GPU'da çalışır.
SFT	<i>Supervised Fine-Tuning</i> — modele "bu girdiye şu çıktı" örneklerini göstererek öğretmek.

A. Kaggle'da Çalıştırma (önerilen — en stabil ücretsiz GPU)

A.1. Hesap ve GPU hakkı

1. kaggle.com → ücretsiz hesap (Google ile girilebilir).
2. **Telefon doğrulaması** yap (Settings → Phone Verification) — bu olmadan GPU açılmaz. Sonrası haftalık ~30 saat ücretsiz GPU.

A.2. Notebook'u yükle

1. **Create → New Notebook → File → Import Notebook.**
2. [gemma3_json_finetune.ipynb](#)'yi seç / sürüküle.

A.3. GPU ve İnterneti aç (KRİTİK)

Sağ panel → **Session options:** - **Accelerator** → **GPU T4 x2** - **Internet** → **On** (*model + veri indirilecek; kapalıysa çalışmaz!*)

A.4. Çalıştır

- Üstten **Run All**.
- **İlk 2-4 dk:** Unsloth kurulumu + model (~3 GB) indirme.
- **Sonra:** baseline ölçümü → 60 adım eğitim (~10 dk) → sonrası ölçümü.

A.5. Sonucu gör

- **Baseline** hücresi: fine-tune *öncesi* geçerli-JSON oranı (düşük — model gevezelik yapar).
- **Sonrası** hücresi: fine-tune *sonrası* oran (yüksek — tertemiz JSON).
- Referans çalıştırmada: **%0 → %95**.

A.6. Modeli indir (opsiyonel)

- [gemma3-json-lora/](#) klasörü oluşur → sağdaki **Output** sekmesinden indir / Kaggle'da yayınla.

B. Google Colab'da Çalıştırma (alternatif)

1. colab.research.google.com → **File** → **Upload notebook**.
2. **Runtime** → **Change runtime type** → **T4 GPU**.
3. **Runtime** → **Run all**.

C. Sık Karşılaşılan Hatalar ve Çözümleri

Belirti	Sebebi	Çözüm
<code>No CUDA GPUs are available</code>	GPU seçilmemiş	Accelerator = GPU T4 , oturumu yeniden başlat
İndirme takılıyor / <code>ConnectionError</code>	İnternet kapalı	Internet = On
<code>gated repo / 401</code>	Model erişimi	Kaggle → Add-ons → Secrets → <code>HF_TOKEN</code> ekle; notebook notundaki <code>login(...)</code> 'i çalıştır
<code>CUDA out of memory</code>	Bellek doldu	<code>max_seq_length</code> 'i 2048 → 1024 düşür veya oturumu Restart edip baştan çalıştır
<code>NameError / ... not defined</code>	Hücreler sırasız çalıştı	Baştan Run All (yukarıdan aşağı)
Ölçüm çok uzun sürüyor	Baseline'da ham model her örnekte 512 token gevezelik yapıyor	Normal; isterseniz baseline örnek sayısını (20) veya <code>max_new_tokens</code> 'i düşürün

D. Çıktıyı Nasıl Yorumlarız?

- Loss** eğitim boyunca **düşüyorsa** model JSON kalıbını öğreniyordur (referansta 0.42 → 0.13).
- Baseline oranı** (referansta %0) düşük, **fine-tuned oranı** (referansta %95) yüksek olmalı — bu *iyileşmenin objektif kanıtı*.
- Örnek çıktıda `json.loads()` **hatasız** çalışıyorsa → çıktı gerçekten geçerli JSON'dur.

Bilimsel disiplin: "Sanırım iyi oldu" demiyoruz. Öncesini ve sonrasını ayrı test setinde ölçüp kıyaslıyoruz (data leakage yok).

E. Model seçim notu — niçin Gemma 3 4B, Gemma 4 E4B değil?

Bu uygulama önce Gemma 4 E4B ile denendi; ücretsiz Kaggle T4'te **eğitilemedi**: - **T4 (Turing) bfloat16 desteklemez**. Gemma 4 float16'da kararsızdır (NaN) → float32 zorunlu → 8B model 14.5 GB'a sığmaz (OOM). - **Gemma 3 4B** float16'da stabildir → ücretsiz T4'te sorunsuz eğitilir (kanıt: %0 → %95).

Ders: *En yeni model her zaman en doğru seçim değildir*. Gemma 4 QLoRA için bf16'lı Ampere+ GPU (L4/A100, ücretli) gerekir; ücretsiz eğitim için doğru seçim **Gemma 3 4B**.

F. Sonraki Adımlar (öğrenci için)

- `max_steps=60` yerine `num_train_epochs=2` ile **tam eğitim**; oranı tekrar ölç.
 - `jsonschema.validate` ile şemaya uygunluk + alan F1.
 - **Kendi Türkçe verinle** (fatura/dilekçe → JSON) aynı hattı çalıştır — gerçek dünyada asıl beceri budur.
 - **GGUF**'a çevirip **Ollama** ile yerelde çalıştır (offline, ücretsiz).
-

Kaynak veri seti: [paraloq/json_data_extraction](#) (Hugging Face, apache-2.0) — *notebook çalışırken otomatik iner*.