

ANTALYA · LLM TABANLI UYGULAMA GELİŞTİRME

Gemma 3 (4B) Fine-Tuning ile Metinden JSON'a

Dağınık belgeyi, şemaya uyan geçerli JSON'a çeviren bir model eğitiyoruz.

Unsloth · QLoRA (4-bit) — Kaggle / Colab ücretsiz T4 GPU

Dr. Murat Altun



Neden Gemma 3 4B? (Gemma 4 E4B neden değil)

Bu uygulama önce Gemma 4 E4B ile denendi. Ücretsiz Kaggle T4'te gerçek çalıştırmalar:

Gemma 4 E4B

✗ **Yüklemede OOM**

auto / float16 / QAT — hepsi

Gemma 4 E2B

✗ **Eğitimde dtype hatası / OOM**

yükleniyor, ama fine-tune edilemiyor

Gemma 3 4B

✓ **Eğitildi: %0 → %95**

peak 5.9 GB — bu notebook

KÖK NEDEN

T4 (Turing) bfloat16 desteklemez.

Gemma 4 float16'da NaN üretir → float32 zorunlu
→ 8B model 14.5 GB'a sığmaz.

Gemma 3 4B float16'da stabil → ücretsiz T4'te sorunsuz eğitilir.

Ders: En yeni model her zaman en doğru seçim değildir — donanımınla modelin gereksinimi uyuşmalı. Gemma 4 için bf16'lı (Ampere+/L4/A100) ücretli GPU gerekir.

Neden fine-tune? Prompt yetmiyor mu?

Küçük bir modele prompt ile JSON istediğinizde tipik üç sorun:

1

Gevezelik

"İşte JSON'unuz:" gibi giriş ekler; kod bloğu (```) sarar → json.loads() patlar.

2

Şemadan sapma

Alan adını değiştirir, tip tutmaz, olmayan alan uydurur.

3

Tutarsızlık

Aynı girdi, her çağrıda farklı biçim → otomasyona güvenilmez.

HAM MODEL ÇIKTISI (baseline %0)

Tabii! İşte istediğiniz JSON:

```
```json
{
 "ad": "Jane",
 "yas": "kırk",
 "tarih": 2023-03-08
}
```
```

✗ giriş cümlesi ✗ tip hatası ✗ tarih tırnaksız → parse edilemez

Prompt mı, RAG mı, Fine-tune mı?

Doğru araç, çözdüğünüz probleme bağlı. Bizim sorunumuz: format disiplini.

Prompt Engineering

- + Hızlı, sıfır ek maliyet, anında dener.
- Davranışı KALICI değiştiremez; her istekte tekrar tarif.

RAG

- + Modele güncel / dış bilgi ekler.
- Çıktı FORMATINI ve tarzını öğretmez; sadece bağlam verir.

BİZİM SEÇİMİMİZ

Fine-tune

- + Format + davranışı ağırlıklara KALICI işler.
- Veri + kısa eğitim gerekir (ama QLoRA ile ucuz).

Format tutarlılığı = fine-tune probleminin ta kendisi.

İki temel kavram (30 saniyede)

1 · Base mı, Instruct mı?

Base (temel): ham cümle tamamlayıcı. "Başkent?" → cevap vermez, cümleyi sürdürür.

Instruct (-it): komut anlar, cevap verir. BİZ BUNU seçiyoruz — sadece davranışı incelteceğiz.

2 · Quantization — niçin 4-bit?

Modeli belleğe sığdırmak için sayı hassasiyetini düşürürüz.

16-bit · ~8 GB

4-bit · ~3 GB ✓

Doğrulukta ihmal edilebilir kayıp. QLoRA'nın tabanı budur — üstüne küçük 'not kağıdı' (LoRA) adaptörü eklenir.

QLoRA: 4B modeli tek T4'te eğitmek



Gemma 3 4B — DONDURULMUŞ

4-bit nicelenmiş taban ağırlıklar
(eğitilmez, ~4.6 GB VRAM)



LoRA adaptörleri — EĞİTİLİR (küçük)

Ağırlıklar donuk; sadece küçük adaptör matrisleri öğrenir.

4.6 GB

yükleme VRAM (ölçüldü)


5.9 GB

EĞİTİM peak VRAM (14.5'e sığar)

$r=8 \cdot \alpha=8$

kompakt adaptör; küçük veri için ideal

7 Adımda Uygulama Hattı



Adım 5 ↔ 7: aynı testte önce ve sonra — bilimsel karşılaştırma.

Ölçtük — "iyi oldu" demedik

Kaggle T4'te GERÇEK çalıştırma · metrik = geçerli-JSON oranı (json.loads) · ayrı test seti (20 örnek)



Sadece 60 adımlık minik eğitim, ücretsiz T4, ~10 dk. Ham model hiç temiz JSON üretemezken, fine-tune sonrası 20 örneğin 19'u geçerli.

Canlı Demo — Kaggle'da beş tık

1

Yeni Notebook

kaggle.com → Create → Notebook

2

Accelerator = GPU T4

sağ panel → Session options

3

Internet = On

model + veri indirilecek

4

Run All

hücreler sırayla akar

5

Sonucu gör

baseline %0 → sonrası %95 ekrana düşer



İPUCU

Önce baseline hücrelerini gösterin — model gevezelik / bozuk JSON üretir (%0).

Sonra eğitim + sonrası hücresi ile aynı örneğin tertemiz JSON'a döndüğünü canlı gösterin (%95).

Fark = ders.

Sıra Sizde — Geniřletme Ödevleri

1

Tam eğitim

max_steps yerine num_train_epochs=2; oranı yeniden ölçün.

2

Şema doğrulama

jsonschema.validate ile şemaya uygunluk + alan F1 ekleyin.

3

Hiperparametre

r ve α 'yı 8→16→32 tarayıp etkisini gözlemleyin.

4

Kendi veriniz

Türkçe fatura / dilekçe → JSON veri setiyle aynı hattı çalıştırın.

5

Yerel dağıtım

GGUF'a çevirip Ollama ile mini bir çıkarım API'sine bağlayın.

6

Karşılaştırma

Aynı görevi salt-prompt ile deneyip fine-tune ile kıyaslayın.

Küçük model, doğru veriyle büyük iş yapar.



- ✓ QLoRA ile Gemma 3 4B'yi ücretsiz T4'te fine-tune ettik (peak 5.9 GB)
- ✓ Geçerli-JSON oranını %0'dan %95'e çıkardık — gerçek ölçüm
- ✓ Doğru model seçimi: donanımına (T4) uyan Gemma 3 4B, en yeni değil